

東吳大學巨量資料管理學院學士專題成果報告書

Bachelor Degree Program

School of Big Data Management

Soochow University

Report of practices

探究角色“雷神”在電影上映之後，PTT 電影版上對
於其評價的正負情感傾向

學生一、學生二、學生三

指導老師：教授一 助理教授

中華民國 108 年 10 月

摘要

2017 年為台灣全國電影票房統計資訊透明化的完整年度，統計資訊涵蓋上映之電影票房達到百億的銷售金額、4 千萬張以上的銷售票數等。相當多人選擇將看電影作為休閒娛樂，而在電影選擇多樣的時代下，觀眾會透過觀看預告片或是參考電影評論來選擇想看的電影，影評網站即提供一個很好的管道讓觀眾了解電影的相關資訊，除了演員資料、級分評比外，眾多的影評亦是了解電影的重要參考依據。因此，我們希望利用機器學習技術判斷每則評論的情緒傾向，藉此得知該電影正負評價的狀況，並以課堂所學的分類與群聚之技術，完成電影評論的情感分析。

目錄

第一章、緒論(含動機、需求分析).....	1
第二章、研究方法(或步驟).....	1
第一節、data (資料取得說明).....	1
第二節、分析方法.....	1
第三章、結果(成果、實驗畫面等).....	2
第一節、爬蟲.....	2
第二節、斷詞.....	4
第三節、分類情感分析.....	5
第四節、群聚情感分析.....	5
第五節、百度 NLP 的情感分析.....	5
第六節、文字雲.....	6
第四章、結論(含心得).....	10
第一節、現有結論.....	10
第二節、發想(未來的應用).....	11
參考文獻.....	12
組員工作表.....	12

圖目錄

圖 三-1、向量示意圖	5
圖 三-2、整體文字雲結果	6
圖 三-3、中性字詞文字雲結果	7
圖 三-4、非中性詞文字雲結果	7
圖 三-5、正向詞文字雲結果	8
圖 三-6、非正向詞文字雲結果	8
圖 三-7 負向詞文字雲結果	9
圖 三-8、非負向詞文字雲結果	9

表目錄

表 三-1、爬蟲資料示例	3
表 三-2、斷詞示例	4
表 三-3、示例	4
表 三-4、情感分析結果	5
表 三-5、群聚分析結果	5
表 三-6、情感分析結果	6

第一章、緒論(含動機、需求分析)

我們這次的專案主題是“探究角色‘雷神’在電影上映之後，PTT 電影版上對於其評價的正負情感傾向”。我們所使用的文字資料將來自於 PTT 電影版從 2011 年第一部雷神的獨立電影上映之後對電影以及雷神的評價文字。

在完成文字資料的爬取和預處理之後，我們將會對所爬取的評價文字用幾種不同的方法進行情感傾向的分析，再以總體的文字雲趨勢來對照情感傾向分析的結果看兩者是否互相支持。

通過以上步驟的分析，我們就可以得出一個總體的關於“雷神”這個關鍵詞的結論。也就是在 PTT 上的網民對於雷神的綜合情感傾向

第二章、研究方法(或步驟)

第一節、data (資料取得說明)

“雷神”這個關鍵詞從 2011 年第一部獨立電影上映以後就開始出現在 PTT 的電影版討論中(批踢踢實業坊)，隨後在 2013 年和 2017 年獨立電影的第二、三部上映之後也有比較多的討論。因此在 2011-2017 年的時間跨度裡有足夠的文本資料來支持我們做情感傾向分析。

於是我們使用網絡爬蟲爬取了所有和雷神關鍵詞有關的推文、內文和評論，並且保留了評論的用戶名用戶 ID 等基本資料用作後續分析使用。

第二節、分析方法

在得到處理過後的文字評論內容以後，為了方便下一步的情感傾向分析，我們使用了 jieba 模組對我們的評論文字進行斷詞。

為了用監督式學習的方式來分類，我們人工標記了 1,773 條評論的正負情感傾向作為訓練集。使用朴素貝葉斯分類器的假設評論的正向、負向和中性的特徵之間是相互獨立的，這樣分類器就利用了一個把問題簡化過的模型進行計算。

用訓練集訓練出模型以後，使用訊連好的模型標注測試集。取得測試集文

探究角色“雷神”在電影上映之後，PTT 電影版上對於其評價的正負情感傾向 第三章、結果(成果、實驗畫面等)

本的特徵以後，若樣本屬於正向分類的機率是最大的，我們就將這個樣本定義為正向。

在做完分類的情感分析以後，為了研究我們的模型標記的正確率，我們也再次用非監督式學習的方式來做群聚的情感分析。同樣使用人工標記的 1773 條評論的正負情感傾向作為訓練集，並用 doc2vec 模型訓練句子的向量表達(Le, & Mikolov, 2014)。使用這個訓練好的模型就可以得到我們所使用的所有樣本的句子向量。

在得到句子向量之後使用 K-means 來做群聚的分類標記。隨機選取 k 個中心點，再將每個樣本的句子向量劃分到最近的中心點中，隨後計算每個群聚的平均值作為新的中心點。隨後不斷重複一直到 k 的中心點收斂到不再變化，我們就會得到分為三群的樣本，就可以分為正向、中性和負向。

我們也使用了已經比較完善的百度 NLP 所內建的情感傾向分析模塊，對我們的文本進行分析(百度 AI 開放平台)。

百度 NLP 的 API 可用於，對每一句評論文本進行分析以後就會輸出樣本的分類、分類的置信度、樣本正向可能性和樣本負向可能性。

在完成不同方式的情感傾向分析以後，我們選擇用文字雲的方式來進行驗證。

我們使用了 R 語言的 Wordcloud2 模組，利用詞與詞的間隔來插入數據，根據文字來繪製定制化的文字雲。

根據斷詞以後的結果，詞語的出現頻率越高，在文字雲裡那個詞就會越大，分為兩個不同的部分進行輸出：第一部分是整體評論的文字雲，第二部分是三個不同情感分類的文字雲。在第一次輸出後，由於效果不是很顯著，所以我們去掉了停用詞再次輸出。

第三章、結果(成果、實驗畫面等)

第一節、爬蟲

在爬蟲結束以後，一共有 583 篇推文和 26436 條對於電影的評論。

對推文我們爬取並保留的欄位有作者的 ID、推文的分類、貼文的標題、作者的用戶名、推文的內文、發布時間和發佈網址。

探究角色“雷神”在電影上映之後，PTT 電影版上對於其評價的正負情感傾向 第三章、結果(成果、實驗畫面等)

具體如下圖：

表 三-1、爬蟲資料示例

ID
M. 1304220326. A. 4CA
M. 1304266791. A. 30E
classify
[好雷]
[好雷]
title
親愛的神-雷神索爾 〈Thor〉
【雷神索爾】：眾人成就的英雄佳片
author
keviner (223)
jalinfly (第蛆艦隊)
content
['\n在敘述【雷神索爾】之前，有幾位
['\n 網誌版: http://jalin.pi
website
https://www.ptt.cc/bbs/movie/M.1304
https://www.ptt.cc/bbs/movie/M.1304
time
Sun May 1 11:25:22 2011
Mon May 2 00:19:48 2011

對於評論我們爬取並保留的欄位有原推文作者的 ID、原推文作者的用戶名、評論的標籤、評論者的用戶名、評論內容和發佈時間。

具體如下圖：

表 三-3、示例

ID
M. 1304220326. A. 4CA
M. 1304220326. A. 4CA
author
keviner (223)
keviner (223)
tag
推
推
ipdatetime
05/01 11:30
05/01 11:48
userid
dotaviper
jennypotato
content
推一個 我沒注意到母后是蕾妮羅素
突然想到肯尼斯布萊納與艾瑪湯普遜者

第二節、斷詞

表 三-2、斷詞示例

jieba
/之前/, /有/幾件/事情/得/先/知道 /, /除了/對/於/漫畫/的/脈絡/略有 /知悉/以外/, /當/\n/然/不能/忘 /的/還有/肯尼斯/布萊納/, /他/第 一部/執導/的/電影/叫做/【/亨利/ 五世/】/, /深蘊/宮廷/內鬥及 /\n/古典/浪漫/, /又/嫻/熟/於/ 大場面/的/操作/。/從此/以/後/肯
jieba
推一個/我/沒/注意/到/母后/是蕾妮 羅素 突然/想到/肯尼斯/布萊納/與/艾瑪 湯/普遜/都/在/霍格華茲/教書/.

在爬蟲以後我們對爬到的內文內容和評論內容的分詞結果如下：

第三節、分類情感分析

使用樸素貝葉斯分類器的模型標注的分類情感分析的結果如下：

表 三-4、情感分析結果

sentiment_classification
1
1
2
1
1
1
1

第四節、群聚情感分析

使用人工標注的訓練集訓練出的 dov2vec 模型輸出的評論文本的向量如下：

```

0      [ 0.02317488 -0.01593496 -0.01504559 -0.001217...
1      [-0.01973362 0.0223389 0.00490762 -0.012425...
2      [-0.00730275 -0.00332936 0.00364656 -0.004551...
3      [-0.00506392 0.01070901 0.0081876 0.004745...
4      [-0.02466021 -0.00475928 0.00645955 -0.008336...
5      [-0.02116273 -0.01364365 0.00932686 0.000409...
6      [-0.0019279 -0.00029549 -0.00872641 0.011359...
```

圖 三-1、向量示意圖

使用 K-means 做出的群聚結果如下：

表 三-5、群聚分析結果

sentiment_cluster
2
2
0
2
2
2

第五節、百度 NLP 的情感分析

使用百度 NLP 的 API 接口所輸出的樣本的分類、分類的置信度、樣本正向

探究角色“雷神”在電影上映之後，PTT 電影版上對於其評價的正負情感傾向 第三章、結果(成果、實驗畫面等)

可能性和樣本負向可能性如下：

表 三-6、情感分析結果

sentiment	
	2
	2
	2
	2
	2
confidence	
	0.990072
	0.986242
	0.974865
	0.971017
	0.966024
posi_prob	
	0.995532
	0.993809
	0.988689
	0.986958
	0.984711
nega_prob	
	0.00446774
	0.00619091
	0.0113107
	0.0130422
	0.015289

第六節、文字雲

第一項、整體文字雲

整體文字雲的輸出結果如下：



圖 三-2、整體文字雲結果

探究角色“雷神”在電影上映之後，PTT 電影版上對於其評價的正負情感傾向
第三章、結果(成果、實驗畫面等)

第二項、不同情感傾向的文字雲

情感傾向標記為中性的文字雲的輸出結果如下：



圖 三-3、中性字詞文字雲結果

去掉停用詞以後的情感傾向標記為中性的輸出結果如下：



圖 三-4、非中性詞文字雲結果

探究角色「雷神」在電影上映之後，PTT 電影版上對於其評價的正負情感傾向 第三章、結果(成果、實驗畫面等)

情感傾向標記為正向的文字雲的輸出結果如下：



圖 三-5、正向詞文字雲結果

去掉停用詞以後的情感傾向標記為正向的輸出結果如下：



圖 三-6、非正向詞文字雲結果

探究角色「雷神」在電影上映之後，PTT 電影版上對於其評價的正負情感傾向 第三章、結果(成果、實驗畫面等)

情感傾向標記為負向的文字雲的輸出結果如下：



圖 三-7 負向詞文字雲結果

去掉停用詞以後的情感傾向標記為負向的輸出結果如下：



圖 三-8、非負向詞文字雲結果

第四章、結論(含心得)

第一節、現有結論

我們這次所做的情感傾向分析是基於對文本裡面包含的信息的抽取，提煉出詞語或者短語元素，再對所提取的特徵元素進行降維之後進行分析。讓情感持有者產生情緒的實體就是我們這次所要分析的關鍵詞“雷神”。通過現有的語料庫中的統計特性，觀察一些具有特徵的現象來挖掘語料庫中的評價詞語並且判斷極性。因為 PTT 論壇中的評論的語法以及表達都不是很規範，所以不太適合使用建立情感元素詞典的方式來進行分析，更適合採用人工標注情感傾向的正負和機器學習交替進行的方法來對模型進行訓練。

首先是分類情感分析的結果，根據我們所訓練的模型標注的句子的情感傾向，有 52%與我們人工標記的情感極性是相同的。也就是說使用監督式學習的朴素貝葉斯分類器在我們的模型的預測準確性是 52%。

其次是群聚情感分析的結果，根據我們所訓練的模型標注的情感傾向，第一群：22%的資料在我們的標記中為負向、54%是中性、24%是正向。第二群：27%的資料在我們的標記中為負向、49%是中性、24%是正向。第三群：26%的資料在我們的標記中為負向、47%是中性、27%是正向。

最後是百度 NLP 的情感分析的結果，百度所輸出的情感傾向標記和我們人工標記的 2533 篇中有 70%是一致的。也就是說百度 NLP 的情感傾向分析標記的預測準確性大致是 70%。

在三種不同方式的情感傾向標記做完以後，我們使用畫文字雲的方式來視覺化我們所抓取的資料的大致的情感傾向。通過短語元素的出現頻率來直觀地觀察評論樣本的綜合情感傾向。此外，因為這次的專案分析主題是有關於雷神的內容，所以我們文字雲的背景是雷神舉著的雷神之鎚 Mjölnir。

整體文字雲的輸出結果可以看到，出現頻率比較高的詞語基本上都是與雷神相關的人物名字或者電影片名。這可以說明關於雷神討論大部分還是集中在電影本身的內容上，而不是演員本人等其他的方面。從整體文字雲的結果上並不能完全呈現關於雷神評論內容的情感傾向。

由於三個情感傾向的文字雲差異不是非常顯著，我們考慮了是停用詞的原因，因而在標記為正向的樣本分詞中去掉了停用詞重新輸出了一個結果。可以看到正向的文字雲輸出以後明顯帶有“支持”、“喜歡”、“很棒”、“超棒”等含有強烈正向情緒的詞。情感傾向為中性的文字雲更多的是對電影本身

人物或者劇情的討論。情感傾向為負向的文字雲則集中在“失望”、“沒差”、“最差”等含有負向情緒的詞。通過文字雲的呈現可以看出，我們情感分析的結果每個感情傾向的文字雲的大體趨勢都是正確的。

第二節、發想(未來的應用)

一個有可能導致偏差的問題在於我們使用的是未進行二次處理的原始資料，也就是其中的語句不完全是規範的，表達方式也有很多不一樣的種類，例如注音、拼音、縮寫等。其中包括很多網絡用意、文字、台語音譯等我們現有模型無法計算特徵向量值的內容。同時，這些不規範的表達方法在文字雲的呈現上也會帶來一些影響。PTT 上的網民發表評論的表達方式有一些都比較雷同，這也會影響到我們關於停用詞的處理。這些都是使用真實的中文原始文字資料會導致的問題。

但是針對這個問題，我們對原始的 26436 條評論進行了大致的人工篩選，篩去了一些無意義的語句，最後留下了 26126 條評論作為最後的文本內容。

另外一個可能導致偏差的問題在於訓練集的取樣方法，因為我們在做標記事前的文本是未標記過的，所以屬於隨機取樣。這樣就會導致取樣的 0、1、2 分類數量不平均，因此導致對較少的分類特徵值的量也會比較少。

但是針對這個問題，我們在分群結果出來以後重新選取了比例大致相當的 0、1、2 分類評論，並且重新進行人工標注，以求三個分類的評論樣本數量達到大致的平衡。

另外還有一個可能導致偏差的問題就是 PTT 會將一部分評論分行截斷，這樣也會導致語義的不完整不通順，這會影響到句子特徵值向量的產生。

雖然針對可能產生問題的兩個因素我們都進行了初步的處理，但是最後結果仍然不是非常理想，我們認為應該還是 PTT 上的發言文本不是那麼規範的緣故。

參考文獻

Le, Q., & Mikolov T. (2014). Distributed representations of sentences and documents. Proceedings of the 31st International Conference on International Conference on Machine Learning, 1188-1196.

批踢踢實業坊。電影版。民 108 年 5 月 20 日，取自

<https://www.ptt.cc/bbs/movie/index.html>

百度 AI 開放平台。NLP-API。民 108 年 4 月 25 日，取自

<http://ai.baidu.com/docs#/NLP-API/top>

組員工作表

學生一：PTT 爬蟲、分類及聚類分析之建模

學生二：文字雲製作、PPT 製作

學生三：百度 NLP 之建模、標記評論、企劃書製作